

Интерпретируемость transformer-моделей прогноза погоды

Технический отчёт по репозиторию `weather-interpretability`

1 августа 2026 г.

Аннотация

Настоящий отчёт разбирает содержимое репозитория `weather-interpretability` — исследовательский проект по интерпретируемости трёх transformer-based моделей прогноза погоды: **Pangu-Weather** (Huawei), **Aurora** (Microsoft) и **Stormer**. Центральный кейс — тайфун *Bebinca* (Китай, сентябрь 2024), сопоставляемый со спокойным контрольным периодом (ноябрь 2024). К моделям применяется набор методов интерпретируемости: occlusion saliency, causal input patching, skeleton (interpolative) decomposition скрытых представлений, а также СКА, Tucker- и NMF-разложения и RepE-style PCA над attention-весами. В отчёте описаны методология, структура репозитория, ключевые количественные и качественные результаты, а также итоговые выводы проекта.

Содержание

1	Введение	1
1.1	Исследуемые модели	2
1.2	Технологический стек	2
2	Структура репозитория	2
3	Методология и результаты по экспериментам	3
3.1	Верификация и базовая визуализация (ноутбуки 01–03)	3
3.2	Сравнение моделей (ноутбуки 04–06)	4
3.3	Skeleton (interpolative) decomposition — флагманский эксперимент	5
3.4	Причинное input patching (ноутбук 08)	6
3.5	Tensor-разложения и структура внимания (ноутбук 09)	7
4	Итоговые выводы	9

1 Введение

Проект посвящён вопросу: *что именно "видят" и используют* современные transformer-модели прогноза погоды при прогнозировании экстремальных метеорологических событий, в частности тропических циклонов, по сравнению со спокойной синоптической обстановкой. В отличие от классических численных моделей погоды (NWP), transformer-based модели являются "чёрными ящиками и вопрос их интерпретируемости напрямую связан с доверием к таким системам в оперативном прогнозировании.

Работа выполнена на кластере AIRI (4×NVIDIA V100-32GB). Основной исследуемый случай — тайфун **Bebinca**, обрушившийся на Китай в сентябре 2024 года, в паре с спокойным контрольным периодом (ноябрь 2024, без циклонической активности). Для верификации методологии также использованы более ранние случаи: шторм *Eunice* (Атлантика,

февраль 2022), европейская волна тепла с блокингом (июль 2022) и спокойный день (октябрь 2021).

1.1 Исследуемые модели

- **Pangu-Weather** (Huawei) — 3D Earth-Specific Transformer, распространяется в формате ONNX, разрешение сетки 0.25° , 13 уровней давления. Из-за формата ONNX не даёт прямого доступа к промежуточным активациям, поэтому используется только в occlusion-экспериментах и verification campaign.
- **Aurora** (Microsoft) — энкодер Perceiver + backbone на базе 3D Swin-Transformer U-Net, PyTorch, 0.25° , 1.26 млрд параметров. Основной объект большинства экспериментов данного проекта.
- **Stormer** — плоский Vision Transformer из 24 одинаковых блоков, работает на более грубой сетке 1.40625° (128×256). Используется как независимая архитектурная проверка выводов, полученных на Aurora.

GraphCast (модель на основе графовых нейросетей) осознанно исключена из рассмотрения, поскольку не относится к transformer-архитектурам.

1.2 Технологический стек

- **PyTorch 2.13** (CUDA 12.6) — инференс Aurora и Stormer; **onnxruntime-gpu** — инференс Pangu-Weather;
- **captum** — библиотека интерпретируемости (occlusion/saliency);
- **xarray + zarr + gcsfs + dask** — работа с данными ARCO ERA5 (Zarr на Google Cloud Storage);
- **Cartopy, matplotlib** — визуализация геопространственных полей;
- **microsoft-aurora** — официальный пакет модели Aurora.

Данные ground truth — переанализ **ARCO ERA5** (Google Research). Точная климатология для метрик аномалий взята из **WeatherBench2** (day-of-year $\times$ hour, период 1990–2019).

2 Структура репозитория

Основной нарратив проекта организован в виде 10 последовательных Jupyter-ноутбуков (01_era5_visualization.ipynb ... 10_multi_storm_statistics.ipynb), каждый из которых опирается на результаты, посчитанные тяжёлыми GPU-скриптами (**run_*.py**), и визуализируется отдельными скриптами построения графиков (**plot_*.py**) либо непосредственно внутри ноутбука. Данные и веса моделей не хранятся в git — соответствующие директории (**data/**, **results/**, **model_weights/**) являются символическими ссылками на общее сетевое хранилище кластера.

Компонент	Назначение
0N_*.ipynb	Основной нарратив, 10 последовательных этапов исследования
run_*.py	Тяжёлые GPU-вычисления (инференс моделей, прогоны)
compute_*.py	Постобработка и вычисление метрик/разложений
plot_*.py	Построение графиков вне ноутбуков
figures/	Итоговые PNG/GIF результаты по каждому эксперименту
data/, results/	Символические ссылки на shared-хранилище кластера

Таблица 1: Структура репозитория

3 Методология и результаты по экспериментам

3.1 Верификация и базовая визуализация (ноутбуки 01–03)

Ноутбук **01** готовит и визуализирует поля ERA5 (T2M, MSLP, ветер на 10 м, Z500) для трёх ранних кейсов — шторма Eunice, волны тепла с блокингом и спокойного контроля.

Ноутбук **02** реализует *occlusion saliency* на модели Pangu-Weather (24-часовой прогноз): по-переменное затенение входа (обнуление и замена на климатологию), пространственное patch-occlusion по полям MSLP и Z500, сравнение искажённого/базового прогноза с истинными данными ERA5. Важный методологический результат: канал, формально показавший наибольшую "значимость" (Z на 850 гПа), оказался артефактом орографии над Чукоткой/Камчаткой — тот же паттерн воспроизводится и в спокойном контрольном случае, что говорит о ложноположительном сигнале, а не о реальной физической значимости.




Рис. 1: Пространственная occlusion-значимость по полю MSLP (шторм Eunice, Pangu-Weather).

Ноутбук **03** строит корреляционные матрицы между выходными каналами Pangu-Weather (69 каналов). Глобальная корреляционная структура физически осмысленна: geopotential когерентен по всем 13 уровням давления, влажность и температура образуют собственные блоки, компоненты ветра u/v разделены. Локальная пространственная корреляция (скользящее окно) признана известным артефактом метода — шумной из-за малого размера окна на гладких полях, без физической интерпретации.




Рис. 2: Матрица корреляции выходных аномалий Pangu-Weather.

3.2 Сравнение моделей (ноутбуки 04–06)

Ноутбуки **04–06** последовательно расширяют сравнение трёх моделей (Pangu-Weather 6h, Aurora, Stormer) по метрикам RMSE и ACC (anomaly correlation coefficient) на 96 инициализациях (2024–2025, по 4 инициализации в месяц, шаг 6 ч до +48 ч). Ноутбук 06 добавляет точную климатологию WeatherBench2 вместо грубой месячной аппроксимации и вводит дополнительные диагностики: смещение (bias), отношение дисперсий (variance ratio — индикатор "размытия" прогноза AI-моделями), корреляцию с климатологией и зональный энергетический спектр.




Рис. 3: RMSE и ACC в зависимости от заблаговременности прогноза: Pangu-Weather, Aurora, Stormer. Метрики Stormer систематически смещены out-of-scale за счёт более грубой сетки и не сравниваются напрямую с Pangu/Aurora.

Важная методическая оговорка: Stormer работает на грубой сетке 1.40625° , что приводит к сглаживанию полей и завышению ACC — это явно отмечено на графиках и не интерпретируется как реальное превосходство модели.




Рис. 4: Карта ошибки MSLP в районе Китая, тайфун Bebinca, +24ч.

3.3 Skeleton (interpolative) decomposition — флагманский эксперимент

Ноутбуки **07** и **10** составляют центральную часть проекта. Метод основан на *interpolative decomposition* (rank-revealing QR, `scipy.linalg.interpolative.interp_decomp`), применённой к скрытым состояниям backbone моделей Augora (три стадии энкодера) и Stormer (мелкий, средний и глубокий блок из 24). В отличие от SVD/PCA, метод выбирает не абстрактные собственные векторы, а конкретные реальные точки сетки ("landmarks") — минимальный набор пикселей, через линейную комбинацию которых можно восстановить всё остальное скрытое представление.

Ранг разложения $k = 256$ выбран через развёртку по k (`sweep_k.py`): для мелкой стадии энкодера порог относительной ошибки < 0.15 достигается уже при $k \approx 192-256$, тогда как для глубоких bottleneck-стадий тот же порог не достигается даже при $k = 512$ — глубокие слои упаковывают больше информации на канал.




Рис. 5: Развёртка по рангу разложения k : относительная ошибка восстановления по стадиям энкодера.

Главный положительный результат. Landmarks row-skeleton разложения кластеризуются в области экстремума завихренности на уровне 850 гПа — то есть в центре тропического циклона (тайфун Bebinca). Это подтверждено парным спокойным контролем: в тот же процедуру, применённой к спокойному дню (15 ноября 2024), landmarks не кластеризуются

вокруг сопоставимого vorticity-экстремума у Тайваня, а рассеиваются по сетке. Результат воспроизведён на двух архитектурно разных моделях — Aurora (Swin U-Net) и Stormer (плоский ViT).




Рис. 6: Landmarks skeleton-разложения на карте завихренности (850 гПа), +24ч. Слева: случай тайфуна Bebinca — landmarks концентрируются в центре циклона. Справа: спокойный контроль — landmarks рассеяны, кластеризации нет.

Статистическое подтверждение (ноутбук 10). Эксперимент расширен на $N = 6$ независимых тропических циклонов (2018–2023, плюс Bebinca 2024, центры верифицированы по базе IBTrACS), каждый с парным спокойным контролем того же года и сезона. Результат: во всех 6 из 6 случаев число landmarks у истинного центра шторма больше, чем в парном спокойном дне (sign test $p = 0.031$, доверительный интервал bootstrap не включает ноль). Это первый результат проекта, подкреплённый статистикой на выборке $N > 1$. Дополнительно показано, что в спокойные дни landmarks не распределены случайно, а кластеризуются на самой сильной локальной динамической структуре дня (фронты, отсечённые циклоны, антициклоны) — то есть модель в общем случае маршрутизирует представление к наиболее интенсивной динамической особенности, и тропические циклоны оказываются лишь частным (наиболее интенсивным) случаем такой особенности.




Рис. 7: Отслеживание landmarks относительно траектории шторма во времени.

Негативный результат. Та же процедура skeleton decomposition, применённая к матрицам внимания (Q–K, по головам), даёт landmarks на краях и углах пространственного окна независимо от входных данных. Это структурный артефакт rank-revealing QR (метод предпочитает граничные точки для интерполяции гладких полей), а не физический сигнал — что подтверждается идентичным паттерном в спокойном контроле. Авторы отмечают перспективное направление: раскладывать не сами матрицы внимания, а их разность между штормовым и спокойным случаями.

3.4 Причинное input patching (ноутбук 08)

В отличие от пассивной skeleton decomposition, эксперимент 08 — причинный: поочерёдно заменяется *один* компонент входа (приземное MSLP, ветер, mass field, температура, T2M) на среднюю климатологию, остальные компоненты входа остаются реальными, после чего выполняется полный rollout до +24 ч и сравнение с базовым (неповреждённым) прогнозом. Сравниваются случаи шторма (Bebinca) и спокойного периода, глобальный и региональный масштаб.

Используется 6 метрик: RMSE между повреждённым и базовым прогнозом, изменение RMSE относительно истины, изменение ACC, относительная чувствительность (безразмерная), area-weighted RMSE и storm-focused RMSE с гауссовым весом вокруг трека минимума MSLP.




Рис. 8: Карта ошибки MSLP при патчинге компонента ветра на климатологию (шторм Vebinsa, +24ч).

Результат. Патчинг ветра и mass field сильнее всего искажает поля геопотенциала — что отражает физическую взаимосвязанность динамического и массового полей (wind-mass balance), а не независимость переменных друг от друга. Приземное MSLP демонстрирует непропорционально широкое влияние на прочие переменные для двумерного поля — то есть в структуре чувствительности выражена не диагональная, а кросс-переменная зависимость. Аналогичный эксперимент на Stormer (одношаговый прямой forward, без авторегрессии, на грубой сетке) подтверждает те же качественные паттерны на независимой архитектуре.




Рис. 9: Взвешенное по площади и по трекингу шторма сравнение RMSE между экспериментами патчинга.

3.5 Tensor-разложения и структура внимания (ноутбук 09)

Пять дополнительных методов применены к парам storm/quiet (переиспользуя скрытые состояния из эксперимента 07 и новый hook на веса внимания):

1. **Спектр сингулярных значений / эффективный ранг (SVD)** — *отрицательный результат*: кривые накопленной энергии для шторма и спокойного случая почти неразличимы на каждой стадии энкодера. Сжимаемость представления — структурное свойство глубины backbone, а не свойство, зависящее от события.
2. **СКА (Centered Kernel Alignment) между головами внимания** — *положительный результат*: головы внимания менее избыточны и более специализированы в ре-

альном штормовом случае (средняя off-diagonal СКА: 0.740 против 0.886 на мелкой стадии; 0.500 против 0.532 на средней).

3. **Tucker-разложение** (по головам, запросам, ключам) — независимо подтверждает результат СКА более строгим численным методом: для ошибки восстановления $< 10\%$ штормовому случаю требуется полный ранг по всем 8 головам на мелкой стадии, тогда как спокойному — на одну голову меньше.
4. **RepE-style PCA** на разности скрытых состояний storm—quiet — *осторожный/отрицательный результат*: первая главная компонента (38% дисперсии) описывает широкий север-южный градиент по всему региону — похоже на сезонный confound (сентябрь против ноября), а не изолированный сигнал тайфуна. Сформулирован методологический вывод: для чистоты сравнения нужны либо множественные contrastive пары в рамках одного сезона, либо переиспользование инфраструктуры патчинга (эксперимент 08) для сравнения реального и патченного входа *в ту же дату*.
5. **NMF** на весах внимания — выявляет более чистую аддитивную структуру (вертикальные полосовые паттерны), общую для шторма и спокойного случая — архитектурное свойство, не специфичное для события. При этом NMF выявляет иную "головы-выброс" (голова 2, мелкая стадия), чем СКА (голова 5) — указывая, что головы внимания различаются сразу по нескольким независимым осям (что вычисляется vs как маршрутизируется).




Рис. 10: Слева: матрица СКА между головами внимания. Справа: доля накопленной энергии эффективного ранга по стадиям энкодера (storm vs quiet).




Рис. 11: Проекция RepE-style PCA на разности скрытых состояний storm–quiet.

4 Итоговые выводы

1. **Основной положительный результат проекта** — Aurora и Stormer (две архитектурно разные transformer-модели) при обработке представления тропического циклона выделяют реальные пространственные точки сетки (landmarks), кластеризующиеся в центре циклона по завихренности на 850 гПа. Эффект статистически подтверждён на выборке из 6 независимых штормов ($p = 0.031$) и воспроизводится относительно парных спокойных контролей.
2. **Модель специализируется, а не расширяется, под воздействием интенсивного события:** СКА и Tucker-разложение согласованно показывают снижение избыточности между головами внимания в штормовом случае, при неизменном эффективном ранге (SVD) скрытого представления — то есть модель перераспределяет "разделение труда" между головами, а не увеличивает объём задействованной информации.
3. **Причинная абляция (input patching) подтверждает физическую состоятельность модели:** искажение компонентов ветра/mass field портит геопотенциальные поля сильнее прочих — модель усвоила физическую связь wind–mass balance, а не рассматривает переменные как независимые каналы.
4. **Явно задокументированные отрицательные результаты и методологические артефакты** — важная часть научной строгости проекта: occlusion-saliency на неверных орографических каналах, edge-артефакт skeleton decomposition на матрицах внимания, сезонный confound в RepE PCA. Каждый негативный результат подтверждён контрольным (quiet) прогоном.
5. **Ограничение по моделям:** Pangu-Weather, распространяемая только в формате ONNX, не даёт доступа к промежуточным активациям, поэтому участвует только в occlusion-saliency и verification campaign; методы, требующие доступа к скрытым состояниям (skeleton decomposition, tensor decomposition), применены только к Aurora и (частично) Stormer.